목차

6. 트위터 API 를 활용한 관광지 검색 데이터 수집

(2017.06 / Python)

7. 야구 선수 데이터의 점수화를 통한 스카우팅 분석

(2015.12 / R, Oracle)

@ Git 주소 : https://github.com/Q3333

1. 의사결정나무와 로지스틱 회귀분석을 활용한 타이타닉 생존자 예측

[개인, Kaggle Competition에서 도전한 프로젝트])

https://www.kaggle.com/c/titanic/submissions

위 링크에서 도전해본 타이타닉 생존자 데이터를 이용한 결과 값 예측 프로젝트이다.

상세 내용은 아래 Git Link에 정리

https://github.com/Q3333/Study_Project/tree/master/Project%20-%20Titanic%20prediction

1-1. 첫 시도는 Kaggle 튜토리얼을 통해 배운 Pandas 조작으로 그룹핑을 해서 의미 있는 column을 찾아 보았다.

fare를 평균보다 더 낸 사람들의 집단을 정리해서 따로 DF를 생성하였다.

```
rate_fare = sum(af)/len(af)

print("% of fare high who survived:", rate_fare)
```

```
% of fare high who survived: 0.676829268292683
```

결과는 약 67%가 생존

참고 : 전체 생존율은 약 38%이다.

```
total = sum(train.Survived)/len(train.Survived)

print("% of survived:", total)
```

```
% of survived: 0.3838383838383838
```

1-2. 두 번째는 의사결정나무를 활용해서 생존 여부를 예측해 보았다.

의사결정나무 - target 변수와 feature 변수 나누기

Pclass~Embraked 항목을 feature로

```
feature_names = ["Pclass", "Sex", "Age",
                 "SibSp", "Parch", "Fare", "Embarked"]
```

```
X_train = train[feature_names]

print(X_train.shape)
X_train.head()
```

Survived를 target으로 설정

```
label_name = "Survived"

y_train = train[label_name]

print(y_train.shape)
y_train.head()
```

1-3. 마지막으로 target과 train을 나누는 과정에서 영감을 얻어서 로지스틱 회귀 분석을 시도했다.

로지스틱 회귀분석 - 변수선택(유의확률을 기반으로)

train 데이터에서 종속변수를 Survived로 두고, Pclass부터 Embarked까지의 모든 변수를 넣은 모형을 확인

```
import statsmodels.api as sm

reg = sm.OLS.from_formula("Survived ~ Pclass + Sex + Age + SibSp + Parch + Fare + Embarked", train).fit()
reg.summary()
```

	coef	std err	t	P>|t|	[0.025	0.975]
Intercept	0.7897	0.070	11.211	0.000	0.651	0.928
Sex[T.1]	0.5031	0.028	17.824	0.000	0.448	0.558
Pclass	-0.1752	0.020	-8.849	0.000	-0.214	-0.136
Age	-0.0060	0.001	-5.546	0.000	-0.008	-0.004
SibSp	-0.0419	0.013	-3.216	0.001	-0.067	-0.016
Parch	-0.0156	0.018	-0.855	0.393	-0.051	0.020
Fare	0.0003	0.000	0.994	0.320	-0.000	0.001
Embarked	0.0423	0.020	2.101	0.036	0.003	0.082

유의확률이 0.05보다 높은 두 변수를 제거하고 다시 확인

```
reg = sm.OLS.from_formula("Survived ~ Pclass + Sex + Age + SibSp + Embarked", train).fit()
reg.summary()
```

로지스틱 모델 학습

로지스틱 회귀모형에 각각 학습 데이터들을 적용시킴

```
from sklearn.linear_model import LogisticRegression
logreg = LogisticRegression()
logreg.fit(x_train, y_train)
```

각각의 Score 는 로지스틱이 76, 의사결정 나무가 77 점이 나왔다

2. Naive bayes 를 활용한 네이버 댓글 긍부정 분석기

[개인, 책을 통해 공부를 하면서 만들어 본 프로젝트])

전체 과정은 https://github.com/Q3333/Study_Project

2-1 유저에게 기사 URL과 학습 데이터의 개수를 입력 받음

```
In [2]: URL = input("네이버 뉴스 기사 댓글창의 URL을 복사해서 입력해주세요")

        #https://sports.news.naver.com/news.nhn?oid=477&aid=0000282510&m_view=1&sort=LIKE - 손흥민, 긍정이 많음

네이버 뉴스 기사 댓글창의 URL을 복사해서 입력해주세요https://news.naver.com/main/ranking/read.nhn?sid1=&rankingType=popular_memo&oid=001&aid=0011552671&date=20200416&type=1&rankingSectionId=100&rankingSeq=1&m_view=1&includeAllCount=true&m_url=%2Fcomment%2Fall.nhn%3FserviceId%3Dnews%26gno%3Dnews001%2C001155267l%26sort%3Dlikability

In [3]: train_number = input("원하는 학습 데이터의 개수를 입력해 주세요")

원하는 학습 데이터의 개수를 입력해 주세요20
```

2-2 유저가 학습데이터의 긍,부정 여부를 판단

```
    else :
        print("pass")
        train_count = train_count + 1
        continue

    train_list.append((text,NB))
    train_count = train_count + 1
    print("")


print(train_list)
```

```
0번째 train data 입니다. 남은 학습 수 : 30
손흥민 지렸다
학습 데이터의 긍부정 여부를 입력해 주세요
긍정 : 1 , 부정 : 2, 중립 :3 : 1
긍정입니다

1번째 train data 입니다. 남은 학습 수 : 29
레이나 야신모드에 놀라고 손흥민 극장골에 놀랐다
학습 데이터의 긍부정 여부를 입력해 주세요
긍정 : 1 , 부정 : 2, 중립 :3 : 1
긍정입니다

2번째 train data 입니다. 남은 학습 수 : 28
손까들이 암만욕해도 결국 에이스는 손흥민이다
학습 데이터의 긍부정 여부를 입력해 주세요
긍정 : 1 , 부정 : 2, 중립 :3 :
```

2-3 형태소 분석 후 학습된 데이터를 바탕으로 단어의 긍,부정 여부를 판단

```
  """)

Most Informative Features
                들이다/Verb = True              neg : pos    =      5.8 : 1.0
                 끄다/Verb = True              neg : pos    =      5.8 : 1.0
                  걸/Noun = True               neg : pos    =      5.8 : 1.0
              이/Determiner = True             neg : pos    =      5.8 : 1.0
                 되다/Verb = True              neg : pos    =      5.8 : 1.0
                  손/Noun = True               neg : pos    =      2.5 : 1.0
                마지막/Noun = True              neg : pos    =      2.5 : 1.0
                 되다/Verb = False             pos : neg    =      2.4 : 1.0
                 하다/Verb = True              neg : pos    =      1.9 : 1.0
             ./Punctuation = True              neg : pos    =      1.9 : 1.0
```

```
[10]: # 위에서 만든 모델에 전체 text data를 넣어 분석
      text_count = 0
```

2-4 결과

```
'그~~~~~~렇게 복하고도 더 팔게있다고 늑날같이 날려드는 손까늘.. 지겹지 않니??? 오늘 경기에서 설설설설 뛴다고 복하더니 결국 극상 반늘었
는데 우짜지??' 의 긍부정 판정 결과는 pos입니다.
'ㅋㅋ 이게 왜 세탁이냐 ㅋㅋㅋ 평점도 최고점 받았는데 ㅋㅋ 진짜 왜 세탁이란건지 하나도 모르겠다 5경기 연속골인데 ㅋㅋㅋ 진짜 얼마나 까고
싶어서 안달난거냐 ㅋㅋ' 의 긍부정 판정 결과는 pos입니다.
'진짜 손흥민 개대박이다 진짜 쇼름돋는다' 의 긍부정 판정 결과는 pos입니다.
'솔직히 손흥민 이달의 선수 각 아니냐?' 의 긍부정 판정 결과는 pos입니다.
```

```
[11]: print("pos 표현의 갯수는 " + str(pos_count) + "개 이며, 약 " + str(round(pos_count/total_length*100,2)) + "%입니다.")
      print("neg 표현의 갯수는 " + str(neg_count) + "개 이며, 약 " + str(round(neg_count/total_length*100,2)) + "%입니다.")
```

```
pos 표현의 갯수는 236개 이며, 약 98.74%입니다.
neg 표현의 갯수는 3개 이며, 약 1.26%입니다.
```

@ 긍,부정의 비율이 어느 한 쪽이 치우쳐진 기사일 경우에는 다른 한 쪽의 학습 데이터가 부족해져서 전체 학습데이터의 양을 늘려야 할 것 같다.

3. 위키피디아 API 를 활용한 마인드맵 사이트

[4인, 멀티캠퍼스 최종 프로젝트])

역할 : 데이터 수집, 전처리, 제공 및 전체적인 기능 개발

전체 내용 : https://github.com/Q3333/Ask_and_Wiki_2019_12

3-1 위키피디아 API에서 텍스트 데이터 추출

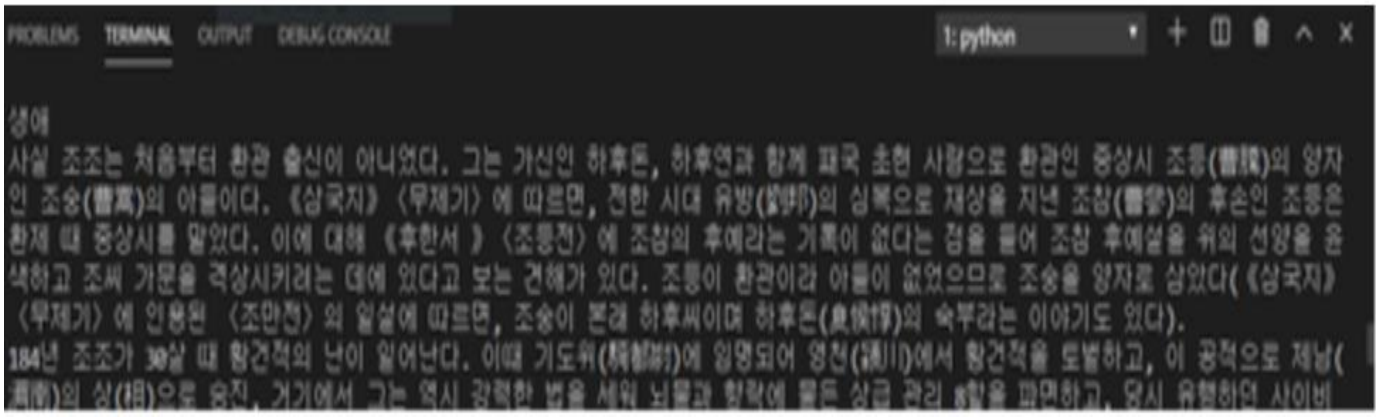

3-2 서브섹션이 있는 경우 TF-IDF를 통해 주요 단어를 추출

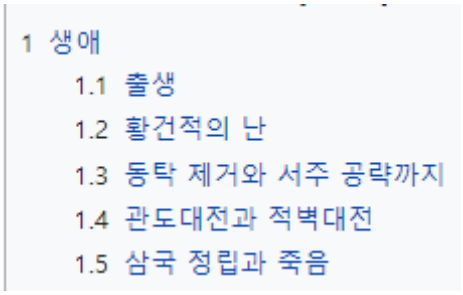

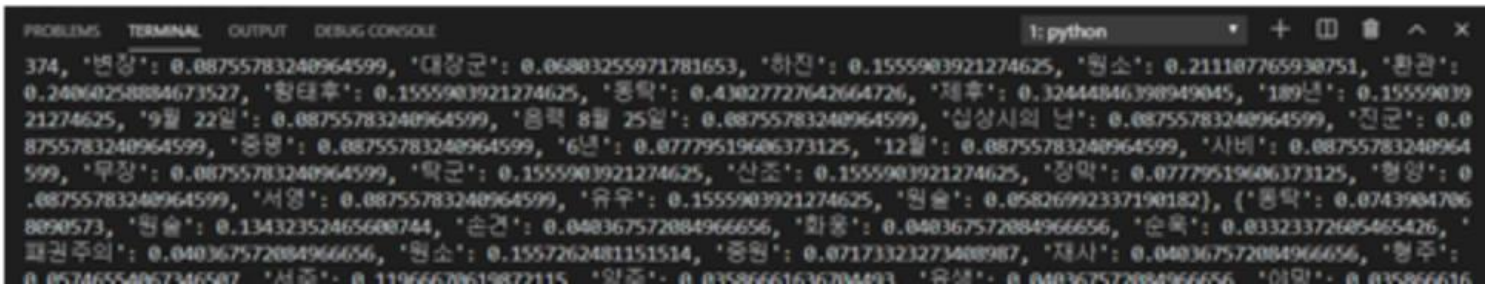

3-3 TF-IDF 분석된 값 중 가장 연관성이 높은 단어들을 마인드맵으로 뿌려줌

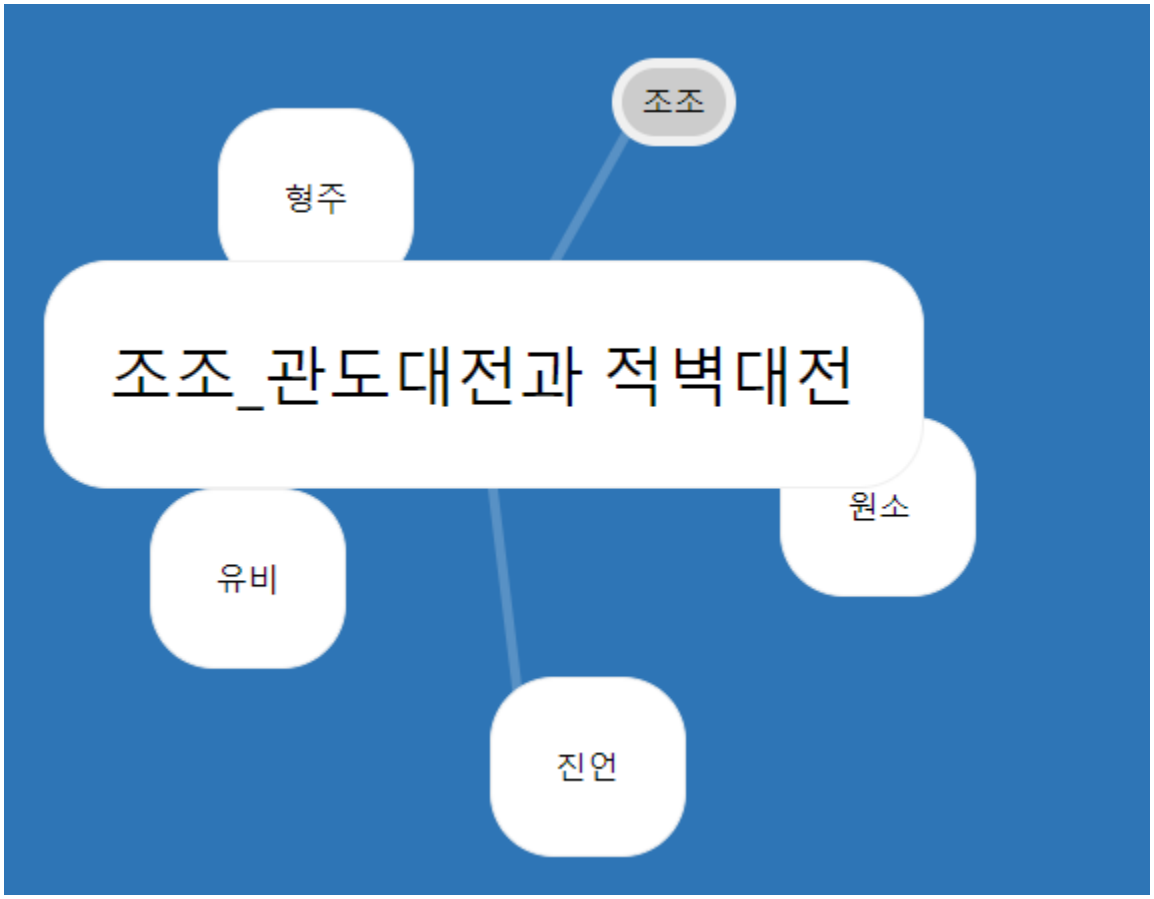

4. 네이버 블로그 검색 API 를 활용한 언급 빈도 시각화

[개인, 멀티캠퍼스에서 배운 R을 이용해 네이버 블로그 검색 API 의 결과를 워드클라우드로 시각화])

결과 :

주요 코드 :

키워드 설정, 조회 개수 설정, 네이버 API 연동

```
#기본 URL
urlStr <- "https://openapi.naver.com/v1/search/blog.xml?"
#검색어 설정 및 UTF-8 URL 인코딩
searchString <- "query=코타키나발루"
#UTF-8 인코딩
searchString <- iconv(searchString, to="UTF-8")
#URL 인코딩
searchString <- URLencode(searchString)
searchString

#나머지 요청 변수 : 조회 개수 1000개, 시작페이지1, 유사도순 정렬
etcString <- "&dispaly=1000&start=1&sort=sim"

#URL 조합
reqUrl <- paste(urlStr, searchString, etcString, sep="")
reqUrl
```

데이터 전처리, 워드클라우드 출력

```
refinedStr <- result
#XML 태그를 공란으로 치환
refinedStr <- gsub("<\\/?)(\\w+)*([^<>]*)>", " ", refinedStr)
#단락을 표현하는 불필요한 문자를 공란으로 치환
refinedStr <- gsub("[[:punct:]]", " ", refinedStr)
#영어 소문자를 공란으로 치환
refinedStr <- gsub("[a-z]", " ", refinedStr)
#영어 대문자를 공란으로 치환
refinedStr <- gsub("[A-Z]", " ", refinedStr)
#숫자를 공란으로 치환
refinedStr <- gsub("[0-9]", " ", refinedStr)
#여러 공란은 한 개의 공란으로 변경
refinedStr <- gsub(" +", " ", refinedStr)
```

```
#제외할 특정 단어를 정의
excluNouns <- c("부터", "하기","이번","오래전","고고해주세용")

nouns  <- nouns [!nouns  %in% excluNouns ]
nouns [1:50]

#빈도수 기준으로 상위 50개 단어 추출
wordT <- sort(table(nouns), decreasing=T)[1:50]
wordT

library(wordcloud2)
wordcloud2(wordT, size=3, shape="diamond")
```

5- 상권분석 API를 이용한 데이터 시각화

[5인, 멀티캠퍼스에서 만난 분들과 참여한 해커톤 프로젝트])

역할 : 수집된 데이터 분석 및 시각화 및 전체적인 웹 개발

전체 프로젝트에 관한 정리는 https://github.com/Q3333/hackathon_2019_06

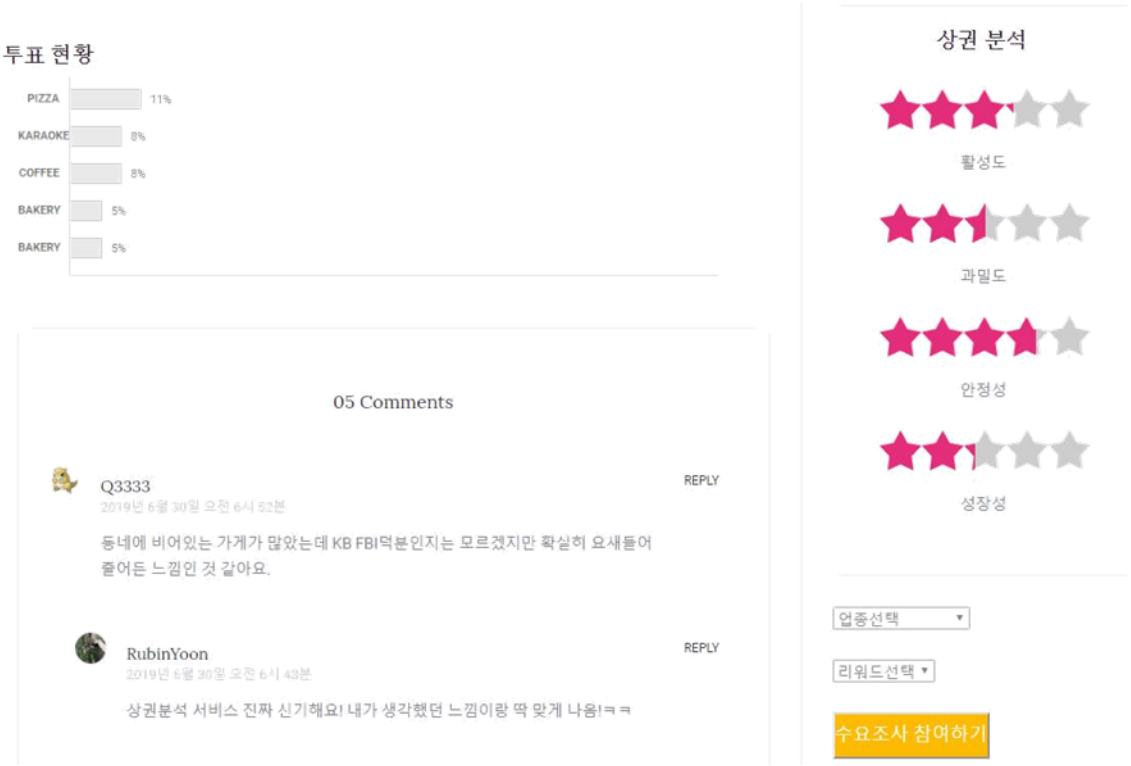

전체 프로젝트는 웹 플랫폼 개발이었는데, 그 중 상권 분석의 4지표를 보기 쉽게 제공하는 방법이 뭘까 고민을 하다가 전체 동네의 평균과 최대값, 최소값을 구한 뒤 해당 점포의 위치와 비교를 하여 나온 차이만큼 점수화 하여 별점으로 보여주었다.

6 - 트위터 API를 활용한 관광지 검색 데이터 수집

[개인, 학부 Python 수업에서 배운 내용을 토대로 데이터 크롤링])

결과 화면, 수집 키워드는 ['관광','여행','갔다옴','갔는데','다녀옴']) 이었고, 관광지 이름들을 변수로 언급 될 때 마다 카운팅 되는 식으로 구현하였다.

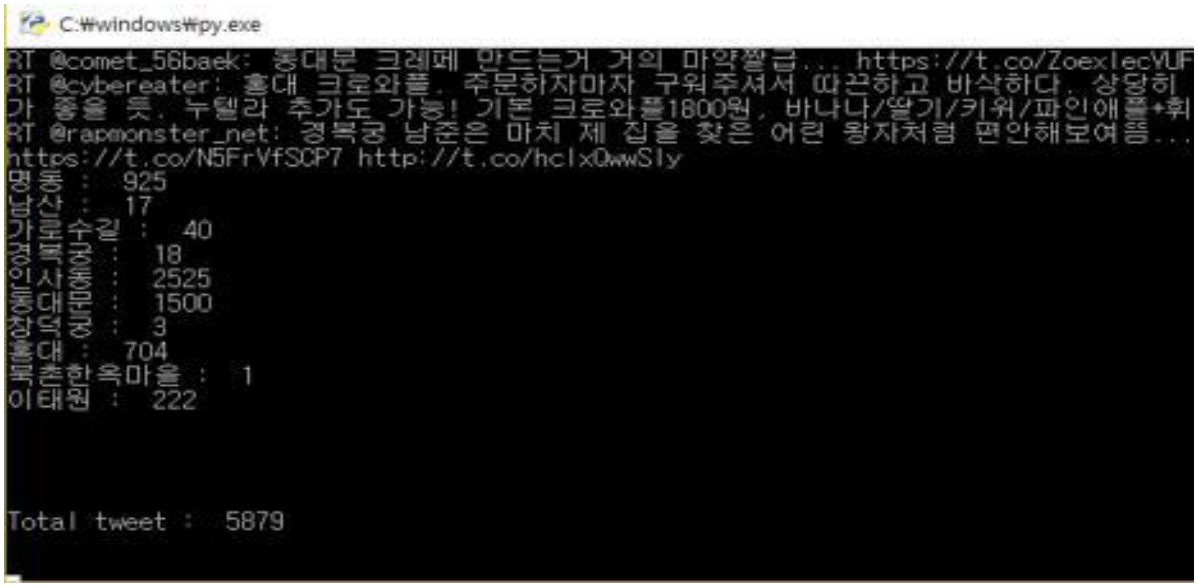

트위피 라이브러리를 사용한 주요 코드

```
from tweepy import Stream
from tweepy import OAuthHandler
from tweepy.streaming import StreamListener


tweet_stream = open('tour.txt', 'a') #raw data를 저장시키기 위해서 txt파일을 변수에 저장한다.

class Listener(StreamListener):

    def on_data(self, data):
        try :
            tweet_stream.write(data) #트위터에서 가져온 데이터를 저장하는 과정
            tweet_stream.write('\n')
            print('suc')
        except :
            print('Err')

        return True

        def on_error(self, status):
            print('error : ', status)
```

7 - 야구 선수 데이터의 점수화를 통한 스카우팅 분석

[2인, 데이터베이스(SQL) 수업 마무리 프로젝트])

역할 : 데이터 수집 및 분석과 아이디어 제안

R을 이용한 상관관계 분석과 데이터베이스 수치들을 이용한 점수화

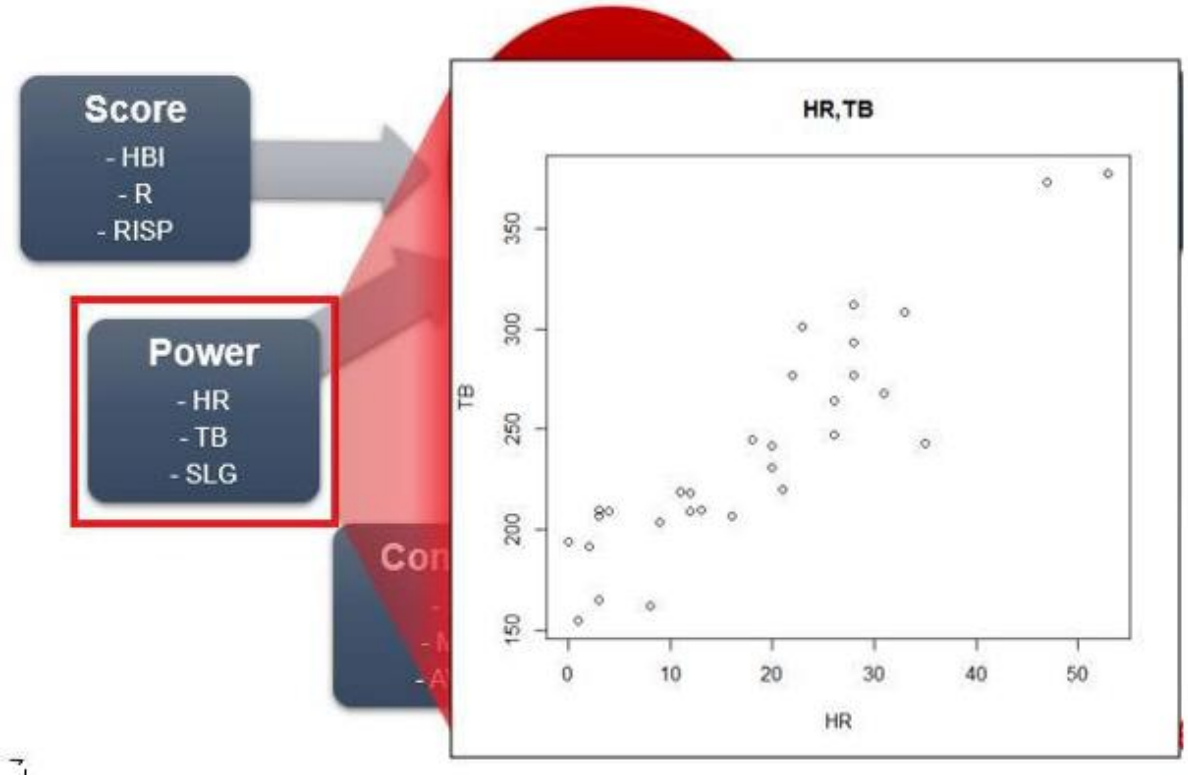

홈런 , 타점의 상관관계 오른쪽 위 방향으로 정비례 한다는 걸 보여준다.

이러한 분석과 비슷한 상관관계 분석을 수 차례 진행한 내용을 바탕으로 기록들

을 6가지로 분류하고 그룹핑해서 점수화.

```
insert into main_table(player_name, SCORE_VALUE, POWER_VALUE, CONTACT_VALUE,
                       BASE_RUNNING_VALUE, ON_BASE_VALUE, DEFENSE_VALUE)
select PLAYER_NAME,
       round((((R+RBI)/5)+(RISP*100)),2) as score,
       round((SLG+(HR_number/TB))*100,1) as power,
       round((((MH+H)/5)+(AVG*100)),2) as contact,
       round(((50+SB)-CS-((OOB+PKO)/2)),2) as base_running,
       round((((BB+HBP)*0.8)/2+(OBP*100)),2) as on_base,
       round(((FPCT-(E/G))*100),2) as defense
```

점수화 과정

Ex) 득점능력이 70이상이거나 파워능력이 80이상인 선수들의 이름과 팀명

```
select player_name, team_name,SCORE_VALUE, POWER_VALUE
from main_table
where score_value >= 70 or power_value >=80;
```

결과

	PLAYER_NAME	TEAM_NAME	SCORE_VALUE	POWER_VALUE
1	Thames	nc	85	91.6
2	yuhanjun	nx	83.3	65.5
3	parkbyungho	nx	92.5	85.5
4	nasungbum	nc	86.1	64.3
5	kimhyunsoo	ds	78.1	64.2
6	parksukmin	ss	83.2	65.6
7	choihyungwoo	ss	73.6	67
8	aduchi	rd	77.6	65.3
9	choijunsuk	rd	71.4	64.5